Práctica 2. EDA y preparación de datasets

Diagnóstico de calidad, decisiones de preprocesamiento y evaluación sobre un clasificador

Equipo

Dávila Martínez Brayan
Hernández Alonso Diego Raymundo
Martínez Rios Edson Jared
Pallares Hernández Oscar

datasets

Titanic
(891 filas)

Telco Customer Churn
(7,043 filas)

Modelo

regresión logística
con validación cruzada de 5 folds

Principio

todo el preprocesamiento
se ajusta solo con datos de entrenamiento



Hallazgo de EDA

El contrato predice el abandono:
en Telco, el tipo de contrato marca la diferencia.

43 % abandono con contrato mensual

11 % abandono con contrato a un año

3 % abandono con contrato a dos años

Mediana de antigüedad: 10 meses vs. 38 meses
entre quienes se van vs. quienes se quedan

Fibra óptica: 42 % de abandono vs. 19 % en DSL



Imputación

Age de Titanic (19.9 % de nulos)

137 valores imputados se concentran en uno solo: pico artificial cerca de los 30 años

13.0 la desviación estándar baja de 14.49 a 13.0

0.801 vs. 0.802 accuracy equivalente
roc-auc: 0.853 en ambas

DECISIÓN mediana y Desconocido: más robustas y sin inventar información

el indicador de ausente no mejoró el modelo



Winsorización de Fare

Percentiles 1 y 99 para tratar valores extremos en Titanic

Asimetría: 4.79 | **Máximo original:** 512.33

IQR	PERCENTILES 1 Y 99
Recorta 91 filas (12.8 %)	Recorta 7 filas (1.0 %)
Máximo resultante: 65.66	Máximo resultante: 227.53
Accuracy: 0.788	Accuracy: 0.802

Los percentiles conservan información legítima de 1.ª clase

DECISIÓN → **PERCENTILES 1 Y 99**



Balanceo

La accuracy puede esconder lo que realmente importa.

0.802 — Accuracy alta sin balanceo, pero el recall es 0.54.

0.80 — Con ponderación de clases, el recall sube a 0.80.

0.626–0.632 — Sobremuestreo, submuestreo y SMOTE rinden casi igual.

0.846 — ROC-AUC se mantiene: el balanceo mueve el punto de corte.

+86
abandonos detectados

+180
falsas alarmas más



Recomendación

Cómo aplicar el modelo y usar los datos para maximizar el impacto del negocio.

1. Usar ponderación de clases si retener es barato y perder un cliente es caro
2. Usar el modelo sin balanceo si las campañas de retención son caras
3. Reportar recall, precisión y F1 junto con la accuracy
4. Priorizar contratos mensuales, clientes nuevos y usuarios de fibra óptica



Limitaciones y uso de IA

Alcance de las conclusiones

Un solo modelo y sin variación entre folds:
diferencias menores a 0.01 no son significativas;

Tratamientos aplicados

Balanceo evaluado solo en Telco; winsorización solo en Fare

Supuesto clave

La recomendación asume que perder un cliente
cuesta más que contactar uno de más

Sesgos y atributos sensibles

Titanic es un dataset histórico con sesgos evidentes;
gender y SeniorCitizen en Telco son atributos sensibles

Asistencia de IA

Se usó Claude (Anthropic) como asistente; el equipo
ejecutó y revisó el código y puede justificar cada decisión

