Ficha técnica de los datasets

Práctica 2 · Titanic y Telco Customer Churn

1. Identificación

	Titanic	Telco Customer Churn
Fuente	Kaggle, competencia *Titanic - Machine Learning from Disaster*, archivo train.csv. kaggle.com/competitions/titanic/data	Kaggle, dataset de BlastChar basado en los *IBM Sample Data Sets*, archivo WA_Fn-UseC_-Telco-Customer-Churn.csv. kaggle.com/datasets/blastchar/telco-customer-churn
Licencia / condiciones	Kaggle la marca como "Subject to Competition Rules". Las reglas permiten usarla solo con fines no comerciales, académicos y de educación, y piden no redistribuirla fuera de la competencia (revisado en Kaggle, oct. 2026).	Kaggle la marca como "Data files © Original Authors": los derechos son de los autores originales (IBM) y no se declara una licencia abierta. La usamos solo con fines académicos.
Dimensiones	891 filas x 12 columnas	7,043 filas x 21 columnas
Unidad de análisis	Un pasajero del Titanic	Un cliente de una telefónica (foto en un momento dado)
Variable objetivo	Survived: 0 = no sobrevivió, 1 = sobrevivió	Churn: Yes = se dio de baja en el último mes, No = sigue como cliente
¿Disponible antes de predecir?	No: se conoce después del naufragio (análisis retrospectivo).	No: se conoce cuando ocurre la baja; un modelo real debe usar datos previos.
Distribución de la clase	549 (61.6 %) vs. 342 (38.4 %). IR = 549/342 = 1.61 > 1.5: desbalanceado (leve)	5,174 (73.5 %) vs. 1,869 (26.5 %). IR = 2.77 > 1.5: desbalanceado (moderado)

2. Variables

Dataset	Tipo	Variables
Titanic	Numéricas	Age (decimal; fraccional si es menor de 1 año), SibSp y Parch (enteros: familiares a bordo), Fare (decimal: tarifa)
	Categóricas	Pclass (1, 2, 3; viene como entero pero es categórica), Sex (male/female), Embarked (C, Q, S)
	Excluidas	PassengerId, Name, Ticket (identificadores o casi únicos) y Cabin (77 % de nulos)
Telco	Numéricas	tenure (entero: meses como cliente), MonthlyCharges (decimal), TotalCharges (llega como texto; se convierte a decimal)
	Categóricas	gender, SeniorCitizen (0/1), Partner, Dependents, PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies, Contract, PaperlessBilling, PaymentMethod
	Excluida	customerID (identificador único)

3. Problemas de calidad detectados

Dataset	Problema	Evidencia	Tratamiento
Titanic	Valores perdidos	Age 177 (19.9 %), Cabin 687 (77.1 %), Embarked 2 (0.2 %)	Age: mediana; Embarked: "Desconocido"; Cabin se excluye
Titanic	Outliers	Fare: asimetría 4.79, máximo 512.33, mediana 14.45	Winsorización en percentiles 1 y 99
Titanic	Valores sospechosos	15 pasajeros con Fare = 0, en las tres clases	Se documentan sin modificar
Telco	Tipo incorrecto y ausentes ocultos	TotalCharges como texto; 11 espacios en blanco, todos con tenure = 0	Conversión numérica; 11 nulos (0.16 %) imputados con mediana en el pipeline
Telco	Categorías redundantes	"No internet service" (1,526) y "No phone service" (682)	Se unifican con "No"
Telco	Correlación alta	tenure-TotalCharges 0.83; TotalCharges casi igual a tenure x MonthlyCharges (dif. mediana 2 %)	Se documenta; no se elimina (afecta coeficientes, no la predicción)
Ambos	Duplicados, constantes y dominio	0 duplicados, 0 columnas constantes, sin etiquetas inconsistentes ni valores fuera de dominio; Telco sin outliers por IQR	No requiere tratamiento

4. Riesgos, fuga de información y ética

- **Identificadores:** PassengerId, Name y customerID son 100 % únicos y Ticket casi; no aportan patrones generalizables y se excluyen.
- **Fuga o información indirecta:** en Titanic, el título dentro de Name (Mr, Mrs, Miss, Master) codifica sexo y edad, y Cabin y Ticket se relacionan con la clase. En Telco, TotalCharges es casi una variable derivada, y tenure y los cargos se registran al momento de la foto, que para quien se fue coincide con su baja; en producción habría que usar datos de antes de la baja.
- **Sesgo y trato desigual:** en Titanic, sexo, clase y edad decidieron quién sobrevivió, así que un modelo reproduce ese sesgo y no debe usarse para decisiones sobre personas. En Telco, gender y SeniorCitizen son atributos sensibles: usarlos para ofertas o atención distinta podría perjudicar a mujeres o adultos mayores.

- **Privacidad y uso:** son datos históricos o de ejemplo sin datos de contacto. Las reglas de Titanic piden no redistribuir los archivos; el CSV se incluye en el repositorio solo para que la práctica sea reproducible con fines académicos.

5. Limitaciones

- Titanic es pequeño (891 filas) y es un solo evento histórico, así que sus conclusiones no se pueden generalizar.
- Telco es un dataset de ejemplo publicado por IBM, con una sola foto de los clientes y sin información temporal ni de costos de retención.
- Titanic supera el umbral de desbalance por poco (IR = 1.61); se comprobó que balancear no mejora su F1, por lo que el análisis completo de balanceo se centró en Telco.
- Todas las comparaciones se hicieron con regresión logística; diferencias menores a la variación entre folds (~0.02 en F1) no deben considerarse mejoras reales.