Ficha técnica de los datasets

Titanic y Telco Customer Churn

1. Identificación

	Titanic	Telco Customer Churn
Fuente	Kaggle, competencia "Titanic - Machine Learning from Disaster" (archivo train.csv)	Kaggle, conjunto de datos "Telco Customer Churn" de IBM, publicado por BlastChar (archivo WA_Fn-UseC_-Telco-Customer-Churn.csv)
Licencia	Sujeta a las reglas de la competencia (según los metadatos del dataset en Kaggle)	Data files © Original Authors (según la tarjeta del dataset en Kaggle): derechos de los autores originales, sin licencia abierta; uso con fines académicos
Unidad de análisis	Un pasajero del Titanic	Un cliente de una empresa de telecomunicaciones
Dimensiones	891 filas x 12 columnas	7,043 filas x 21 columnas
Variable objetivo	Survived (0 = no sobrevivió, 1 = sobrevivió)	Churn (No / Yes): el cliente abandonó el servicio
Distribución de la clase	549 (61.6 %) vs. 342 (38.4 %). IR = 1.60, desbalance leve	5,174 (73.5 %) vs. 1,869 (26.5 %). IR = 2.77, desbalance moderado

2. Variables

Dataset	Tipo	Variables
Titanic	Numéricas	Age, SibSp (hermanos o cónyuge a bordo), Parch (padres o hijos a bordo), Fare (tarifa)
	Categóricas	Pclass (clase 1, 2 o 3; tratada como categórica), Sex, Embarked (puerto de embarque: C, Q, S)
	Identificadores o texto	PassengerId, Name, Ticket, Cabin (se excluyen del modelo; Cabin por tener 77 % de nulos)
Telco	Numéricas	tenure (meses como cliente), MonthlyCharges (cargo mensual), TotalCharges (cargo acumulado)
	Categóricas	gender, SeniorCitizen (0/1), Partner, Dependents, PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies, Contract, PaperlessBilling, PaymentMethod
	Identificador	customerID (se excluye del modelo)

3. Problemas de calidad detectados

Dataset	Problema	Evidencia	Tratamiento
Titanic	Valores perdidos	Age 177 (19.9 %), Cabin 687 (77.1 %), Embarked 2	Age: mediana; Embarked: "Desconocido"; Cabin se excluye
Titanic	Outliers	Fare: asimetría 4.79, máximo 512.33, mediana 14.45	Winsorización en percentiles 1 y 99
Titanic	Valores sospechosos	15 pasajeros con Fare = 0	Se documentan sin modificar
Telco	Tipo de dato incorrecto y ausentes ocultos	TotalCharges viene como texto; 11 vacíos, todos con tenure = 0	Conversión numérica; imputación con mediana en el pipeline
Telco	Categorías redundantes	"No internet service" (1,526) y "No phone service" (682)	Unificadas con "No"
Telco	Correlación alta	tenure y TotalCharges = 0.83; MonthlyCharges y TotalCharges = 0.65	Se documenta; se vigila en modelos lineales
Ambos	Duplicados y columnas constantes	0 filas duplicadas, 0 columnas constantes	No requiere tratamiento

4. Riesgos, fuga de información y ética

- **Disponibilidad de la variable objetivo:** en Titanic la supervivencia se conoce solo después del evento (análisis retrospectivo). En Telco el abandono se conoce al ocurrir, por lo que un modelo real debe predecirlo con información

previa.

- **Fuga potencial:** en Titanic, Name contiene el título (Mr, Mrs, Miss), que codifica sexo y edad, y Cabin y Ticket se relacionan con la clase. En Telco, TotalCharges es casi tenure x MonthlyCharges. Los identificadores (PassengerId, customerID) no aportan información y se excluyen.
- **Sesgo y trato desigual:** en Titanic, sexo, clase y edad determinan la supervivencia, por lo que un modelo reproduce el sesgo histórico y no debe usarse para decisiones sobre personas. En Telco, gender y SeniorCitizen son atributos sensibles que podrían dar lugar a ofertas o atención desiguales.
- **Privacidad:** son datos históricos o de ejemplo, sin datos personales reales identificables a simple vista.

5. Limitaciones

- Titanic es pequeño (891 filas) y es un solo evento histórico, lo que limita la generalización de cualquier conclusión.
- Telco es un dataset de ejemplo publicado por IBM, con una sola instantánea de clientes y sin información temporal ni de costos de retención.
- El desbalance de Titanic es leve (IR = 1.6), por lo que el efecto del balanceo se estudió en Telco.
- Las comparaciones entre estrategias de preprocesamiento se hicieron con regresión logística; diferencias menores a 0.01 en las métricas no deben considerarse significativas.