Informe ejecutivo

Práctica 2. Análisis exploratorio y preparación de datasets: Titanic y Telco Customer Churn

1. Objetivo y datos

Auditamos dos datasets de clasificación para diagnosticar su calidad, justificar las decisiones de preprocesamiento y medir su efecto sobre un clasificador (regresión logística). Las estrategias se compararon con validación cruzada estratificada de 5 folds sobre el entrenamiento (80 %) y las elegidas se evaluaron una sola vez en el conjunto de prueba (20 %). Todo el preprocesamiento se ajustó solo con datos de entrenamiento, dentro de pipelines, para evitar fuga de información.

	Titanic	Telco Customer Churn
Unidad de análisis	Un pasajero	Un cliente
Dimensión	891 x 12	7,043 x 21
Objetivo	Survived (342 sí / 549 no)	Churn (1,869 sí / 5,174 no)
Razón de desbalance (IR)	549 / 342 = 1.61: supera 1.5 (leve)	5,174 / 1,869 = 2.77: supera 1.5 (moderado)
Problema principal	Age 19.9 % nulos, Cabin 77.1 % nulos, Fare con cola larga	TotalCharges como texto con 11 vacíos (clientes con tenure = 0)

2. Hallazgos principales de calidad y EDA

- **Sin duplicados, columnas constantes, etiquetas inconsistentes ni valores fuera de dominio** en ningún dataset. Los identificadores (PassengerId, Name, customerID) son 100 % únicos y se excluyen del modelo.
- **Titanic:** Fare tiene asimetría 4.79 (mediana 14.45, máximo 512.33) y 15 tarifas en 0, que se documentan sin modificar. El sexo y la clase explican gran parte de la supervivencia (74.2 % de las mujeres contra 18.9 % de los hombres; 63.0 % en primera contra 24.2 % en tercera). La edad casi no separa las clases (mediana de 28 años en ambos grupos).
- **Telco:** la ausencia en TotalCharges es estructural: las 11 filas son clientes con tenure = 0. TotalCharges está muy correlacionada con tenure (0.83) y las categorías "No internet service" y "No phone service" repiten información de otras columnas. El IQR no detecta outliers.
- **Hallazgo clave de Telco:** el tipo de contrato separa fuertemente el abandono: 42.7 % en contrato mensual, 11.3 % a un año y 2.8 % a dos años. También destacan la fibra óptica (41.9 % frente a 19.0 % en DSL) y la baja antigüedad (mediana de tenure de 10 meses entre quienes se van, contra 38 entre quienes se quedan).

3. Imputación de valores perdidos

En Titanic se comparó la estrategia A (media para Age, moda para Embarked) con la B (mediana y categoría "Desconocido"), más una variante con indicador binario de ausente. En entrenamiento faltaban 137 edades y 2 puertos de embarque.

Estrategia	Desv. est. de Age	Accuracy	Precision	Recall	F1	ROC-AUC
Original (sin nulos)	14.49	-	-	-	-	-
A: media + moda	13.02	0.801	0.762	0.700	0.729	0.853
B: mediana + Desconocido	13.03	0.802	0.765	0.700	0.730	0.853
B + indicador de ausente	13.03	0.796	0.759	0.692	0.723	0.853

Ambas estrategias meten los 137 valores en un solo número, lo que crea un pico artificial (en 28.5 años con B y en 29.8 con A) y reduce la desviación estándar alrededor de 10 % (la varianza casi 20 %). El desempeño es equivalente: las diferencias (0.007 o menos) son menores que la variación del F1 entre folds (~0.022). Aunque la ausencia de edad sí se asocia con menor supervivencia (29 % contra 41 %), el indicador no mejoró el modelo, probablemente porque esos pasajeros eran sobre todo de tercera clase. **Decisión:** mediana y "Desconocido", por ser robustas y no inventar categorías. Cabin (77 % de nulos) no se imputa.

4. Winsorización de outliers (Fare)

Los límites se calcularon solo con entrenamiento. El criterio IQR (1.5) recortó 91 tarifas (12.8 %) a 65.66; los percentiles 1 y 99 recortaron 7 (1.0 %) a 227.53. En ambos casos el límite inferior no tiene efecto (IQR negativo y percentil 1 = 0).

Versión	Media	Mediana	Desv. est.	Máximo	Asimetría	Accuracy	F1
Sin winsorizar	31.82	14.45	48.06	512.33	4.65	0.802	0.730
IQR (límite 65.66)	23.96	14.45	20.51	65.66	1.08	0.788	0.713
Percentiles 1-99 (límite 227.53)	30.82	14.45	41.00	227.53	2.93	0.802	0.730

Ninguno de los dos criterios mejoró el clasificador: los percentiles mantienen exactamente el desempeño y el IQR lo baja. **Decisión:** percentiles 1 y 99, porque reducen el máximo y la asimetría sin perder información. El IQR descarta tarifas legítimas de primera clase, que no son errores de captura. En Telco no hubo nada que winsorizar.

5. Tratamiento del desbalance

Telco (IR = 2.77), validación cruzada sobre el entrenamiento; métricas de la clase "abandona":

Estrategia	Accuracy	Precision	Recall	F1	ROC-AUC
Sin balanceo	0.802	0.653	0.542	0.592	0.846
Ponderación de clases	0.749	0.518	0.803	0.629	0.846
Sobremuestreo aleatorio	0.748	0.516	0.802	0.628	0.846
Submuestreo aleatorio	0.746	0.514	0.800	0.626	0.846
SMOTE	0.756	0.528	0.791	0.633	0.845

Un modelo que siempre responde "No abandona" alcanza 73.5 % de accuracy, por lo que esa métrica por sí sola es engañosa. Todas las técnicas suben el recall de 0.54 a cerca de 0.80 a costa de precisión, y el F1 de 0.59 a ~0.63. El ROC-AUC no cambia: el balanceo mueve el punto de corte, pero no mejora la capacidad de ordenar clientes por riesgo. Entre técnicas, las diferencias (menos de 0.01) están dentro de la variación entre folds.

Titanic (IR = 1.61) también supera el umbral, así que se probaron las mismas cinco estrategias: el recall sube de 0.70 a ~0.76, pero el F1 no cambia (0.724-0.730). Con un desbalance tan leve, balancear no aporta y se mantuvo el modelo sin balanceo.

Evaluación final en prueba (Telco, 1,409 clientes, 374 abandonos reales): sin balanceo se detectan 207 abandonos (recall 0.553, precision 0.655, F1 0.600, 109 falsas alarmas); con ponderación de clases se detectan 293 (recall 0.783, precision 0.503, F1 0.613, 289 falsas alarmas). Es decir, 86 abandonos más detectados a cambio de 180 falsas alarmas más. En Titanic, el modelo elegido obtuvo en prueba accuracy 0.804, F1 0.724 y ROC-AUC 0.842 (la referencia trivial da 0.615). Las métricas de prueba son parecidas a las de validación cruzada.

6. Recomendación

- Usar **ponderación de clases** si retener a un cliente es barato (un descuento o un mensaje) y perderlo es costoso: rinde igual que las otras técnicas y no duplica, inventa (SMOTE) ni descarta (submuestreo) registros.
- Usar el modelo **sin balanceo**, o ajustar el umbral, si las campañas de retención son caras, porque es más preciso y genera menos falsas alarmas.
- Reportar siempre recall, precision y F1 de la clase minoritaria junto con la accuracy, y priorizar acciones sobre contratos mensuales, clientes nuevos y usuarios de fibra óptica.
- Imputar con mediana y "Desconocido", y winsorizar con percentiles 1 y 99 antes de modelar.

7. Limitaciones

- La comparación se hizo con un solo modelo (regresión logística) y el umbral por defecto de 0.5. Diferencias menores a la variación entre folds (~0.02 en F1) no deben considerarse significativas.
- La winsorización se aplicó solo a Fare; en Telco no se detectaron outliers.

- La recomendación sobre el balanceo supone que perder un cliente cuesta más que contactar a uno de más; ese supuesto debe validarse con datos de costo del negocio.
- En Telco, tenure y los cargos se registran al momento de la baja, lo que en un escenario real podría inflar el desempeño.
- Titanic es un dataset histórico con sesgos evidentes (sexo, clase, edad) y no debe usarse para decisiones sobre personas. En Telco, gender y SeniorCitizen son atributos sensibles que podrían generar un trato desigual si se usan sin justificación.

Declaración de uso de IA

Se utilizó Claude (Anthropic) como herramienta de apoyo durante el desarrollo de la práctica para generar ideas, apoyar con ideas en la estructuración de algunas partes del código y facilitar la interpretación de determinados resultados. También se usó para revisar el trabajo frente a los criterios de evaluación y sugerir correcciones y mejoras de redacción, que el equipo revisó antes de incorporarlas.