Informe ejecutivo

Práctica 2. Análisis exploratorio y preparación de datasets: Titanic y Telco Customer Churn

1. Objetivo y datos

Se auditaron dos datasets de clasificación para diagnosticar su calidad, justificar decisiones de preprocesamiento y medir su efecto sobre un clasificador (regresión logística, validación cruzada estratificada de 5 folds). Todo el preprocesamiento se ajustó solo con datos de entrenamiento, dentro de pipelines, para evitar fuga de información.

	Titanic	Telco Customer Churn
Unidad de análisis	Un pasajero	Un cliente
Dimensión	891 x 12	7,043 x 21
Objetivo	Survived (342 sí / 549 no)	Churn (1,869 sí / 5,174 no)
Razón de desbalance (IR)	1.60 (leve)	2.77 (moderado)
Problema principal	Age 19.9 % nulos, Cabin 77.1 % nulos, Fare con cola larga	TotalCharges como texto con 11 vacíos (clientes con tenure = 0)

2. Hallazgos principales de calidad y EDA

- **Sin duplicados ni columnas constantes** en ningún dataset. Los identificadores (PassengerId, Name, customerID) son 100 % únicos y se excluyen del modelo.
- **Titanic:** Fare tiene asimetría 4.79 (mediana 14.45, máximo 512.33) y 15 pasajeros con tarifa 0, un valor sospechoso que se documenta sin modificar. El sexo y la clase explican gran parte de la supervivencia (la mayoría de las mujeres sobrevivió; la mayoría de los pasajeros de 3.ª clase no).
- **Telco:** la ausencia en TotalCharges es estructural, no aleatoria: las 11 filas corresponden a clientes con tenure = 0. TotalCharges está muy correlacionada con tenure (0.83), y las categorías "No internet service" y "No phone service" son redundantes con otras columnas.
- **Hallazgo clave de Telco:** el tipo de contrato separa fuertemente el abandono: aprox. 43 % en contrato mensual, 11 % a un año y 3 % a dos años. También destacan la fibra óptica (aprox. 42 % de abandono frente a 19 % en DSL) y la baja antigüedad (mediana de tenure de 10 meses entre quienes se van, contra 38 entre quienes se quedan).

3. Imputación de valores perdidos

Se comparó la estrategia A (media para numéricas, moda para categóricas) con la B (mediana y categoría "Desconocido"), más una variante con indicador binario de ausente, sobre Age (137 nulos en entrenamiento) y Embarked (2 nulos).

Estrategia	Desv. est. de Age	Accuracy	F1	Recall	ROC-AUC
Original (sin nulos)	14.49	-	-	-	-
A: media + moda	13.02	0.801	0.729	0.700	0.853
B: mediana + Desconocido	13.03	0.802	0.730	0.700	0.853
B + indicador de ausente	-	0.796	0.723	0.692	0.853

Ambas estrategias concentran los 137 valores imputados en un solo valor, lo que crea un pico artificial cerca de los 30 años, y reducen la desviación estándar cerca de un 10 %. El desempeño es equivalente (diferencias de 0.008 o menos), y el indicador de ausente no mejoró el modelo. **Decisión:** mediana y "Desconocido", por ser robustas a la asimetría y no inventar información. Cabin (77 % de nulos) no se imputa.

4. Winsorización de outliers (Fare)

Los límites se calcularon solo con entrenamiento. El criterio IQR (1.5) recortó 91 filas (12.8 %); los percentiles 1 y 99 recortaron 7 (1.0 %).

Versión	Media	Mediana	Desv. est.	Máximo	Asimetría	Accuracy	F1
Sin winsorizar	31.82	14.45	48.06	512.33	4.65	0.802	0.730
IQR (límite 65.66)	23.96	14.45	20.51	65.66	1.08	0.788	0.713
Percentiles 1-99 (límite 227.53)	30.82	14.45	41.00	227.52	2.93	0.802	0.730

Decisión: percentiles 1 y 99. Conservan el 99 % de los datos, mantienen el desempeño y reducen el máximo y la asimetría. El IQR descarta información legítima (tarifas altas de 1.ª clase, no errores de captura) y bajó ligeramente el desempeño. En Telco, el IQR no detecta outliers en TotalCharges, lo cual también es un resultado válido.

5. Tratamiento del desbalance (Telco, IR = 2.77)

Estrategia	Accuracy	Precision	Recall	F1	ROC-AUC
Sin balanceo	0.802	0.653	0.542	0.592	0.846
Ponderación de clases	0.749	0.518	0.803	0.629	0.846
Sobremuestreo aleatorio	0.748	0.516	0.802	0.628	0.846
Submuestreo aleatorio	0.746	0.514	0.800	0.626	0.846
SMOTE	0.756	0.527	0.791	0.632	0.845

Un modelo que siempre responde "No abandona" alcanza 73.5 % de accuracy, por lo que esa métrica por sí sola es engañosa. Todas las estrategias de balanceo elevan el recall de 0.54 a cerca de 0.80 a costa de precisión; el ROC-AUC no cambia, así que el balanceo mueve el punto de corte pero no mejora la capacidad de ordenar clientes por riesgo. Las cuatro técnicas rinden de forma prácticamente igual (F1 entre 0.626 y 0.632).

Evaluación final en prueba (1,409 clientes, 374 con abandono real): sin balanceo se detectan 207 abandonos (recall 0.55, precision 0.66, 109 falsas alarmas); con ponderación de clases se detectan 293 (recall 0.78, precision 0.50, 289 falsas alarmas). Es decir, 86 abandonos adicionales detectados a cambio de 180 falsas alarmas adicionales.

6. Recomendación

- Usar **ponderación de clases** si retener a un cliente es barato (descuento o mensaje) y perderlo es costoso: rinde igual que las demás técnicas, no duplica ni inventa registros (SMOTE) ni descarta datos (submuestreo).
- Usar el modelo **sin balanceo** si las campañas de retención son caras, porque es más preciso y genera menos falsas alarmas.

- Reportar siempre recall, precision y F1 de la clase minoritaria junto con la accuracy, y priorizar acciones sobre contratos mensuales, clientes nuevos y usuarios de fibra óptica.
- Imputar con mediana y "Desconocido", y winsorizar con percentiles 1 y 99 antes de modelar.

7. Limitaciones

- La comparación entre estrategias se hizo con un solo modelo (regresión logística) y no se midió la variación entre folds, por lo que diferencias menores a 0.01 no deben considerarse significativas.
- El balanceo se evaluó solo en Telco; Titanic (IR = 1.6) se usó para imputación y winsorización. La winsorización se aplicó únicamente a Fare.
- La recomendación sobre el balanceo supone que perder un cliente cuesta más que contactar a uno de más; ese supuesto debe validarse con datos de costo del negocio.
- Titanic es un dataset histórico con sesgos evidentes (sexo, clase, edad) y no debe usarse para decisiones sobre personas. En Telco, gender y SeniorCitizen son atributos sensibles que podrían generar un trato desigual si se usan sin justificación.
- El IR de Titanic (1.6) apenas supera el umbral de 1.5, por lo que su desbalance es leve y las estrategias de balanceo tendrían poco efecto.

Declaración de uso de IA

Se utilizó Claude (Anthropic) como asistente para estructurar el código, proponer métricas y apoyar la interpretación de resultados. El equipo ejecutó el código, revisó las salidas y puede justificar el método de imputación, los límites de winsorización y la técnica de balanceo.